

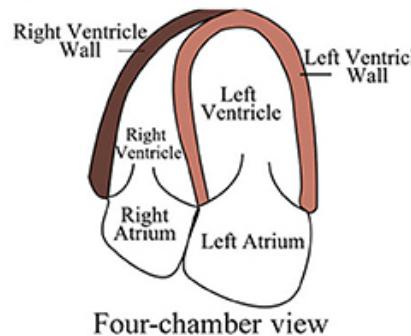
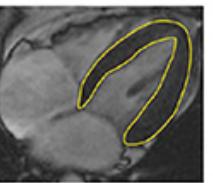
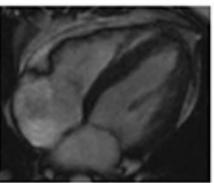
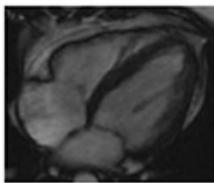
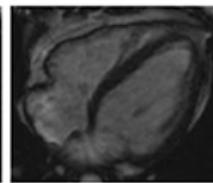
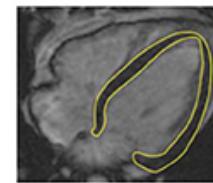
Projects Checklist

Hobot | Deep Learning | Zahra Amini

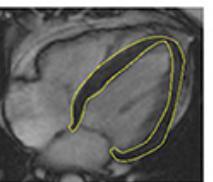
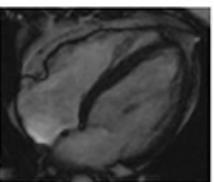
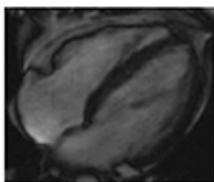
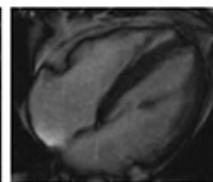
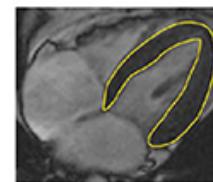
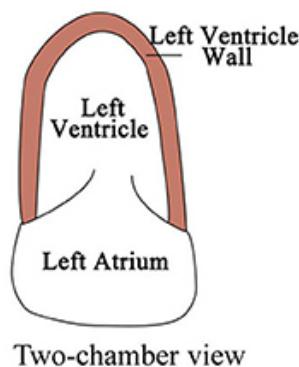
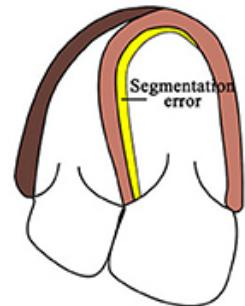
Telegram: @zahraamini_ai & Instagram:@zahraamini_ai & LinkedIn: @zahraamini-ai

<https://zil.ink/zahraamini>

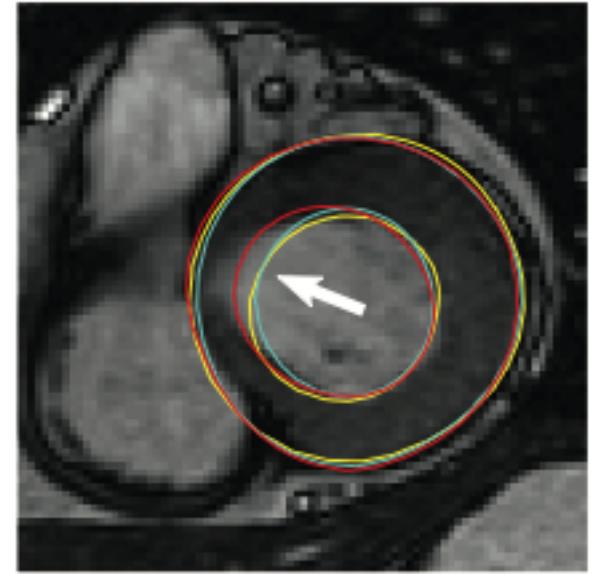
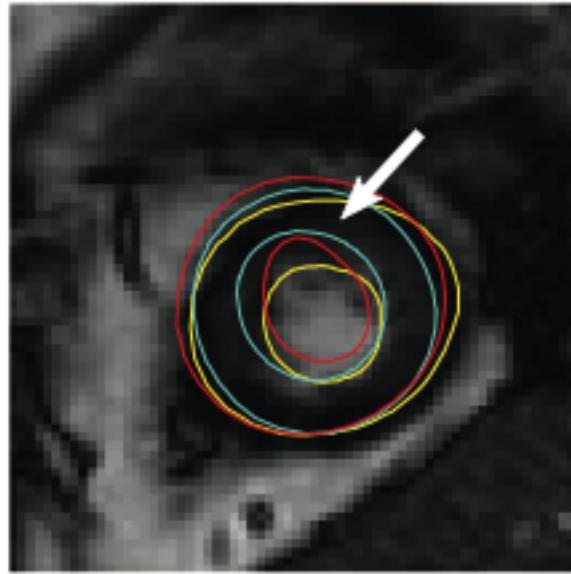
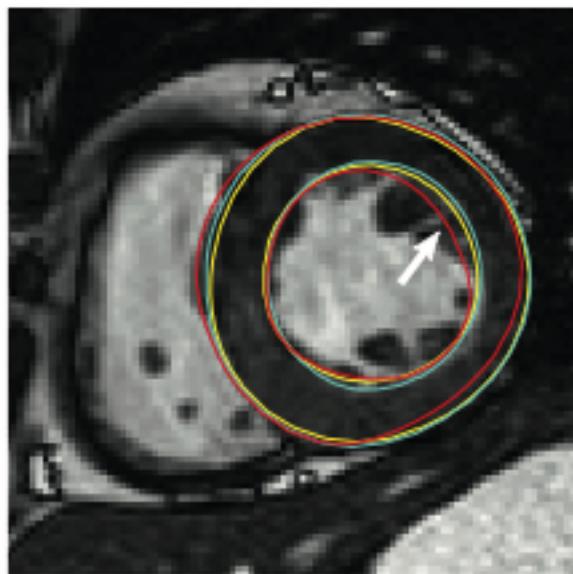
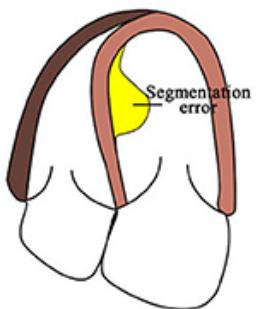
LV Segmentation

A**B**

Contraction

C

Diastole



◦ معرفی مختصر مساله / چالش (تا حد ممکن خلاصه و کوتاه)

◦ بخش‌های اصلی بیان مساله

▪ تعریف دقیق و مختصری از مساله

پروژه LV Segmentation (تقسیم‌بندی بطن چپ قلب) در تصاویر پزشکی، بهویژه MRI ، یکی از مهم‌ترین چالش‌ها در حوزه تصویربرداری پزشکی است. هدف این پروژه استفاده از داده‌های ACDC برای انجام تقسیم‌بندی دقیق بطن چپ قلب است. این تقسیم‌بندی به پزشکان کمک می‌کند تا وضعیت قلب بیماران را بهتر بررسی و تشخیص‌های دقیق‌تری ارائه دهند.

▪ هدف از حل مساله یا چالش

هدف اصلی از این پروژه، بهبود دقیق و کارایی در تقسیم‌بندی بطن چپ در تصاویر MRI با استفاده از مدل‌های یادگیری عمیق است. این بهبود می‌تواند منجر به تشخیص بهتر و زودتر بیماری‌های قلبی شود، که در نهایت می‌تواند به نجات جان بیماران منجر شود.

▪ نیازمند جستجو، مطالعه، تفکر و سوال

جستجو و مطالعه: بررسی روش‌های موجود برای تقسیم‌بندی بطن چپ قلب و شناسایی الگوریتم‌های موثر در یادگیری عمیق برای تصویربرداری پزشکی.
تفکر و سوال: آیا روش‌های موجود به اندازه کافی دقیق هستند؟ چگونه می‌توان دقیق و سرعت تقسیم‌بندی را بهبود داد؟ آیا داده‌های موجود برای آموزش مدل کافی هستند؟

▪ اهداف مساله یا چالش

بهبود دقیق تقسیم‌بندی: ایجاد مدلی که بتواند با دقیق بالا مرزهای بطن چپ قلب را تشخیص دهد.

کاهش زمان پردازش: استفاده از روش‌های کارآمد که زمان پردازش تصاویر را کاهش دهد، در حالی که دقیق حفظ می‌شود.

افزایش قابلیت تعمیم: اطمینان از اینکه مدل توانایی تعمیم‌پذیری به انواع مختلف داده‌های MRI را داشته باشد و در شرایط مختلف بالینی عملکرد خوبی ارائه دهد.

• تحلیل امکان‌سنجی پروژه:

◦ بررسی منابع فنی (سخت‌افزار و نرم‌افزار و تعیین نیازهای پروژه).

پردازنده (CPU/GPU): برای پردازش سنگین تصاویر MRI و آموزش مدل‌های یادگیری عمیق، استفاده از GPU های با عملکرد بالا مانند NVIDIA Tesla V100 یا A100 توصیه می‌شود. حافظه یک GPU مورد نیاز است، اما برای تسریع فرآیند آموزش و انجام آزمایش‌های موازی، دسترسی به چندین GPU ایده‌آل است.

◦ بررسی دیتاست‌های موجود و ارزیابی اولیه کیفیت و کاربرد آنها

این دیتاست‌ها همگی منابع معتبری برای پروژه LV Segmentation هستند و بسته به نیاز و شرایط پروژه، می‌توانند از آن‌ها استفاده کنید:

نام دیتاست	حجم و ساختار	کیفیت داده‌ها	تنوع داده‌ها	وضعیت دسترسی
ACDC	MRI 100 مجموعه داده از بیماران با شرایط مختلف قلبی	وضوح بالا، برچسب‌های دقیق توسط متخصصان	بیماران با شرایط نرمال و چندین نوع بیماری قلبی	دسترسی‌پذیر
Sunnybrook Cardiac Data	45 مجموعه داده MRI از بیماران با مشکلات قلبی مختلف	تصاویر با کیفیت بالا، برچسب‌های دقیق	بیماران با مشکلات مختلف	دسترسی‌پذیر
MM-WHS	داده‌های MRI و CT با برچسب‌گذاری برای نواحی مختلف قلب	وضوح بالا، برچسب‌گذاری دقیق برای بطن‌ها و میوکارد	تصاویر MRI و CT از بیماران مختلف	دسترسی‌پذیر
UK Biobank	هزاران MRI قلبی از جمیعت گسترده	تصاویر با کیفیت بالا، برچسب‌های دقیق توسط تیم‌های متخصص	جمعیت گسترده با تنوع بالا در سن، جنسیت و وضعیت سلامتی	محدود دسترسی‌پذیر (نیاز به درخواست رسمی و هزینه)
HVS MR	45 مجموعه داده MRI برای تقسیم‌بندی بطن چپ و راست	تصاویر با وضوح بالا، برچسب‌های دقیق توسط متخصصان	بیماران با شرایط مختلف قلبی	دسترسی‌پذیر

گام 3: برنامه‌ریزی دقیق(Detailed Planning Phase)

• تهیه برنامه زمانی(Timeline):

- تنظیم یک برنامه زمانی دقیق برای هر مرحله از پروژه.

فعالیت‌های کلیدی	تاریخ پایان	تاریخ شروع	مدت زمان	مرحله
مطالعه پیشینه علمی، بررسی دیتاست‌ها، تحلیل امکان‌سنجی، آماده‌سازی مقدماتی محیط کاری			1 هفته	آماده‌سازی و مطالعه اولیه
نصب نرم‌افزارها و کتابخانه‌های لازم، آماده‌سازی دیتاست‌ها، تنظیم GPU و دیگر منابع			1 هفته	آماده‌سازی و نصب محیط کاری
پیاده‌سازی مدل‌های اولیه، انجام آزمایش‌های ابتدایی، ارزیابی اولیه روی بخشی از داده‌ها			2 هفته	پیاده‌سازی اولیه مدل‌ها
تنظیم هایپرپارامترها، بهینه‌سازی عملکرد مدل‌ها، اجرای آزمایش‌های مختلف			3 هفته	بهینه‌سازی مدل‌ها
ارزیابی نهایی مدل‌ها روی داده‌های جدید، تحلیل عملکرد مدل‌ها، ارزیابی کیفیت نهایی			1 هفته	ارزیابی جامع و تست
تهیه گزارش نهایی، مستندسازی کدها و نتایج، آماده‌سازی فایل‌های ارائه (ReadMe و PowerPoint)			1 هفته	مستندسازی و آماده‌سازی ارائه نهایی

• تخصیص منابع

- تخصیص منابع انسانی و فنی مورد نیاز برای هر گام

• **تحیین اهداف قابل اندازه‌گیری (Measurable Goals):**

○ **تحیین اهداف مشخص و قابل اندازه‌گیری برای ارزیابی موفقیت هر مرحله.**

اهداف قابل اندازه‌گیری	هدف	مرحله
- پیاده‌سازی حداقل یک مدل پایه (مثل Net-U)	توسعه و پیاده‌سازی نسخه اولیه مدل‌های تقسیم‌بندی	پیاده‌سازی اولیه مدل‌ها (2 هفته)
- دستیابی به دقت اولیه حداقل 70% بر روی مجموعه داده‌ی آموزشی کوچک		
- اجرای موفق یک دوره آموزشی مدل و ثبت روند کاهش Loss		
- افزایش دقت مدل به حداقل 85% بر روی داده‌های آموزشی و تست	بهبود دقت و کارایی مدل‌ها	بهینه‌سازی مدل‌ها (3 هفته)
- تنظیم و بهینه‌سازی هایبریارامترها و ثبت نتایج بهینه		
- کاهش Loss به کمتر از 0.1 و بهبود F1-Score بالای 0.8		
- انجام حداقل 3 تست مختلف با تنظیمات متفاوت برای انتخاب بهترین مدل		
- دستیابی به دقت نهایی بالای 90% بر روی داده‌های تست	ارزیابی جامع و تست (1 دیده نشده و تحلیل عملکرد هفته)	
- تولید گزارش ارزیابی شامل، Precision, Recall, F1-Score برای هر کلاس		
- شناسایی و مستندسازی نقاط قوت و ضعف مدل		
- تولید و تحلیل حداقل 5 تصویر تقسیم‌بندی شده توسط مدل برای بررسی بصری عملکرد		
- تهیه گزارش جامع شامل تمامی مراحل پروژه	مستندسازی کامل پروژه و آماده‌سازی برای ارائه نهایی	مستندسازی و آماده‌سازی ارائه نهایی (1 هفته)
- آماده‌سازی فایل PowerPoint برای ارائه نهایی		
- مستندسازی کامل کدها و آماده‌سازی فایل ReadMe		
- ذخیره‌سازی و مستندسازی مدل‌ها و داده‌های استفاده شده		

⚠ تمامی حقوق این محتوا متعلق به آکادمی هوبات است. هرگونه کپی‌برداری و انتشار غیرمجاز ممنوع می‌باشد



گام 4: بررسی روش‌های موجود

○ جستجو برای یافتن مهم ترین روش‌های گذشته برای حل مساله

در این گام، شما به بررسی و جستجوی روش‌های مختلفی که در گذشته برای حل مسئله LV Segmentation استفاده شده‌اند، می‌پردازید. هدف این است که با مطالعه روش‌های مختلف، بتوانید بهترین راه حل‌ها را شناسایی و از آن‌ها برای بهبود مدل خود استفاده کنید.

- توضیح مختصر یک پاراگرافی درباره روش‌ها همراه با درج آدرس/لینک

- توصیه: یک جدول خلاصه از روش‌های موجود بسازید

○ از سایتها و ابزارهای زیر استفاده کنید

- گوگل!

- ChatGPT

- Github

- Paperswithcode

- Kaggle

توضیح مختصر یک پاراگرافی درباره روش‌ها همراه با درج لینک:

U-Net: •

- توضیح مختصر U-Net: یکی از محبوب‌ترین مدل‌های یادگیری عمیق برای تقسیم‌بندی تصاویر پزشکی است. این مدل شامل یک ساختار encoder-decoder است که در آن از لایه‌های **encoder** در بخش max-pooling و convolutional استفاده می‌شود و در بخش **decoder** از لایه‌های **upsampling** برای بازسازی ابعاد اصلی تصویر استفاده می‌شود. U-Net به دلیل کارایی بالا در تقسیم‌بندی تصاویر پزشکی، در بسیاری از پروژه‌های مربوط به تقسیم‌بندی قلبی (LV Segmentation) استفاده شده است.

لینک [Paper: U-Net: Convolutional Networks for Biomedical Image Segmentation](#)

Attention U-Net: •

- توضیح مختصر Attention U-Net: یک نسخه بهبود یافته از U-Net است که مکانیزم توجه (attention) را به مدل اضافه می‌کند. این مکانیزم کمک می‌کند تا مدل بتواند به مناطق مهم‌تری از تصویر تمرکز کند و از اطلاعات مفیدتری برای تقسیم‌بندی استفاده کند. این مدل به ویژه در مواردی که نیاز به تشخیص دقیق‌تری از ساختارهای کوچک یا پیچیده در تصویر وجود دارد، عملکرد بهتری دارد.

لینک [Paper: Attention U-Net: Learning Where to Look for the Pancreas](#)

V-Net: •

- توضیح مختصر V-Net: یکی دیگر از مدل‌های یادگیری عمیق است که برای تقسیم‌بندی تصاویر سه‌بعدی پزشکی مانند MRI طراحی شده است. این مدل از لایه‌های 3D convolutional استفاده می‌کند و به دلیل توانایی پردازش اطلاعات سه‌بعدی، بهخصوص برای تقسیم‌بندی ساختارهای پیچیده مانند بطن چپ قلب در تصاویر MRI بسیار مناسب است.

لینک [Paper: V-Net: Fully Convolutional Neural Networks for Volumetric Medical Image Segmentation](#)

نام مدل	توضیح مختصر	لینک
U-Net	مدل U-Net با ساختار encoder-decoder و استفاده از لایه‌های max-convolutional و pooling، برای تقسیم‌بندی دقیق تصاویر پزشکی استفاده می‌شود.	Paper: U-Net
Attention U-Net	نسخه بهبود یافته U-Net با مکانیزم توجه که کمک می‌کند مدل به مناطق مهم‌تر تصویر تمرکز کند و دقت تقسیم‌بندی را افزایش دهد.	Paper: Attention U-Net
V-Net	مدل V-Net با استفاده از لایه‌های 3D convolutional، برای تقسیم‌بندی تصاویر سه‌بعدی پزشکی طراحی شده و مناسب برای پردازش اطلاعات سه‌بعدی است.	Paper: V-Net

تمامی حقوق این محتوا متعلق به آکادمی هوبات است. هرگونه کپی‌برداری و انتشار غیرمجاز ممنوع می‌باشد.

انتخاب یک روش از بین روش‌های بررسی شده در گام_2

در این مرحله، باید یکی از روش‌هایی که در گام 4 بررسی شدند را به عنوان روش اصلی برای پیاده‌سازی در پروژه انتخاب کنید. انتخاب روش مناسب باید با توجه به نیازها و اهداف پروژه انجام شود. برای پروژه LV Segmentation، می‌توانید روش‌های زیر را به عنوان گزینه‌های اصلی در نظر بگیرید:

U-Net: به دلیل سادگی ساختار و کارایی بالا در تقسیم‌بندی تصاویر دو بعدی پزشکی، این مدل یک انتخاب محبوب و موثر است.

Attention U-Net: اگر نیاز به دقیق‌تر و تمرکز‌روری مناطق خاص در تصاویر دارید، این مدل با مکانیزم توجه می‌تواند انتخاب مناسبی باشد.

V-Net: گر پروژه نیاز به پردازش و تقسیم‌بندی تصاویر سه‌بعدی مانند MRI دارد، V-Net با قابلیت‌های 3D convolutional است.

نحوه انتخاب روش مناسب

نوجه به اهداف مطرح شده در گام_1

دقت بالا در تقسیم‌بندی: اگر دقต بالا در تقسیم‌بندی بطن چپ قلب هدف اصلی پیروزه است، مدل‌های U-Net و Attention U-Net مناسب هستند.
سرعت پردازش: اگر سرعت پردازش و آموزش مدل مهم است و پیروزه با محدودیت زمانی روبرو است، Net-U-Net می‌تواند به دلیل ساختار ساده‌تر انتخاب مناسبی باشد.

تعامل با داده‌های سه بعدی: اگر هدف پروژه شامل کار با تصاویر سه بعدی مانند MRI است، انتخاب V-Net منطقی خواهد بود.

نوجه به جزئیات پروژه مانند حجم داده، پیچیدگی روش، سخت افزار

حجم داده: اگر دیتابیست حجم بالایی دارد، باید مدلی را انتخاب کنید که از لحاظ محاسباتی بهینه‌تر باشد و بتواند داده‌های حجمی را به خوبی پردازش کند-U-Net با توجه به سادگی ساختار و قابلیت پردازش موازی در GPU ها گزینه خوبی است.

پیچیدگی روش: اگر پروژه دارای پیچیدگی های بالا در داده های ورودی (مانند ناهنجاری های قلبی) است، U-Net که امکان تمرکز بر جزئیات را فراهم می کند، ممکن است انتخاب بهتری باشد.

GPU های قدرتمند دسترسی ندارید، استفاده از مدل های سبکتر مانند U-Net ساخت افزار بر صورتی که به منابع کمتری نیاز دارند، توصیه می شود.

کارکرد پروژه (کاری/دانشگاهی/آموزشی)

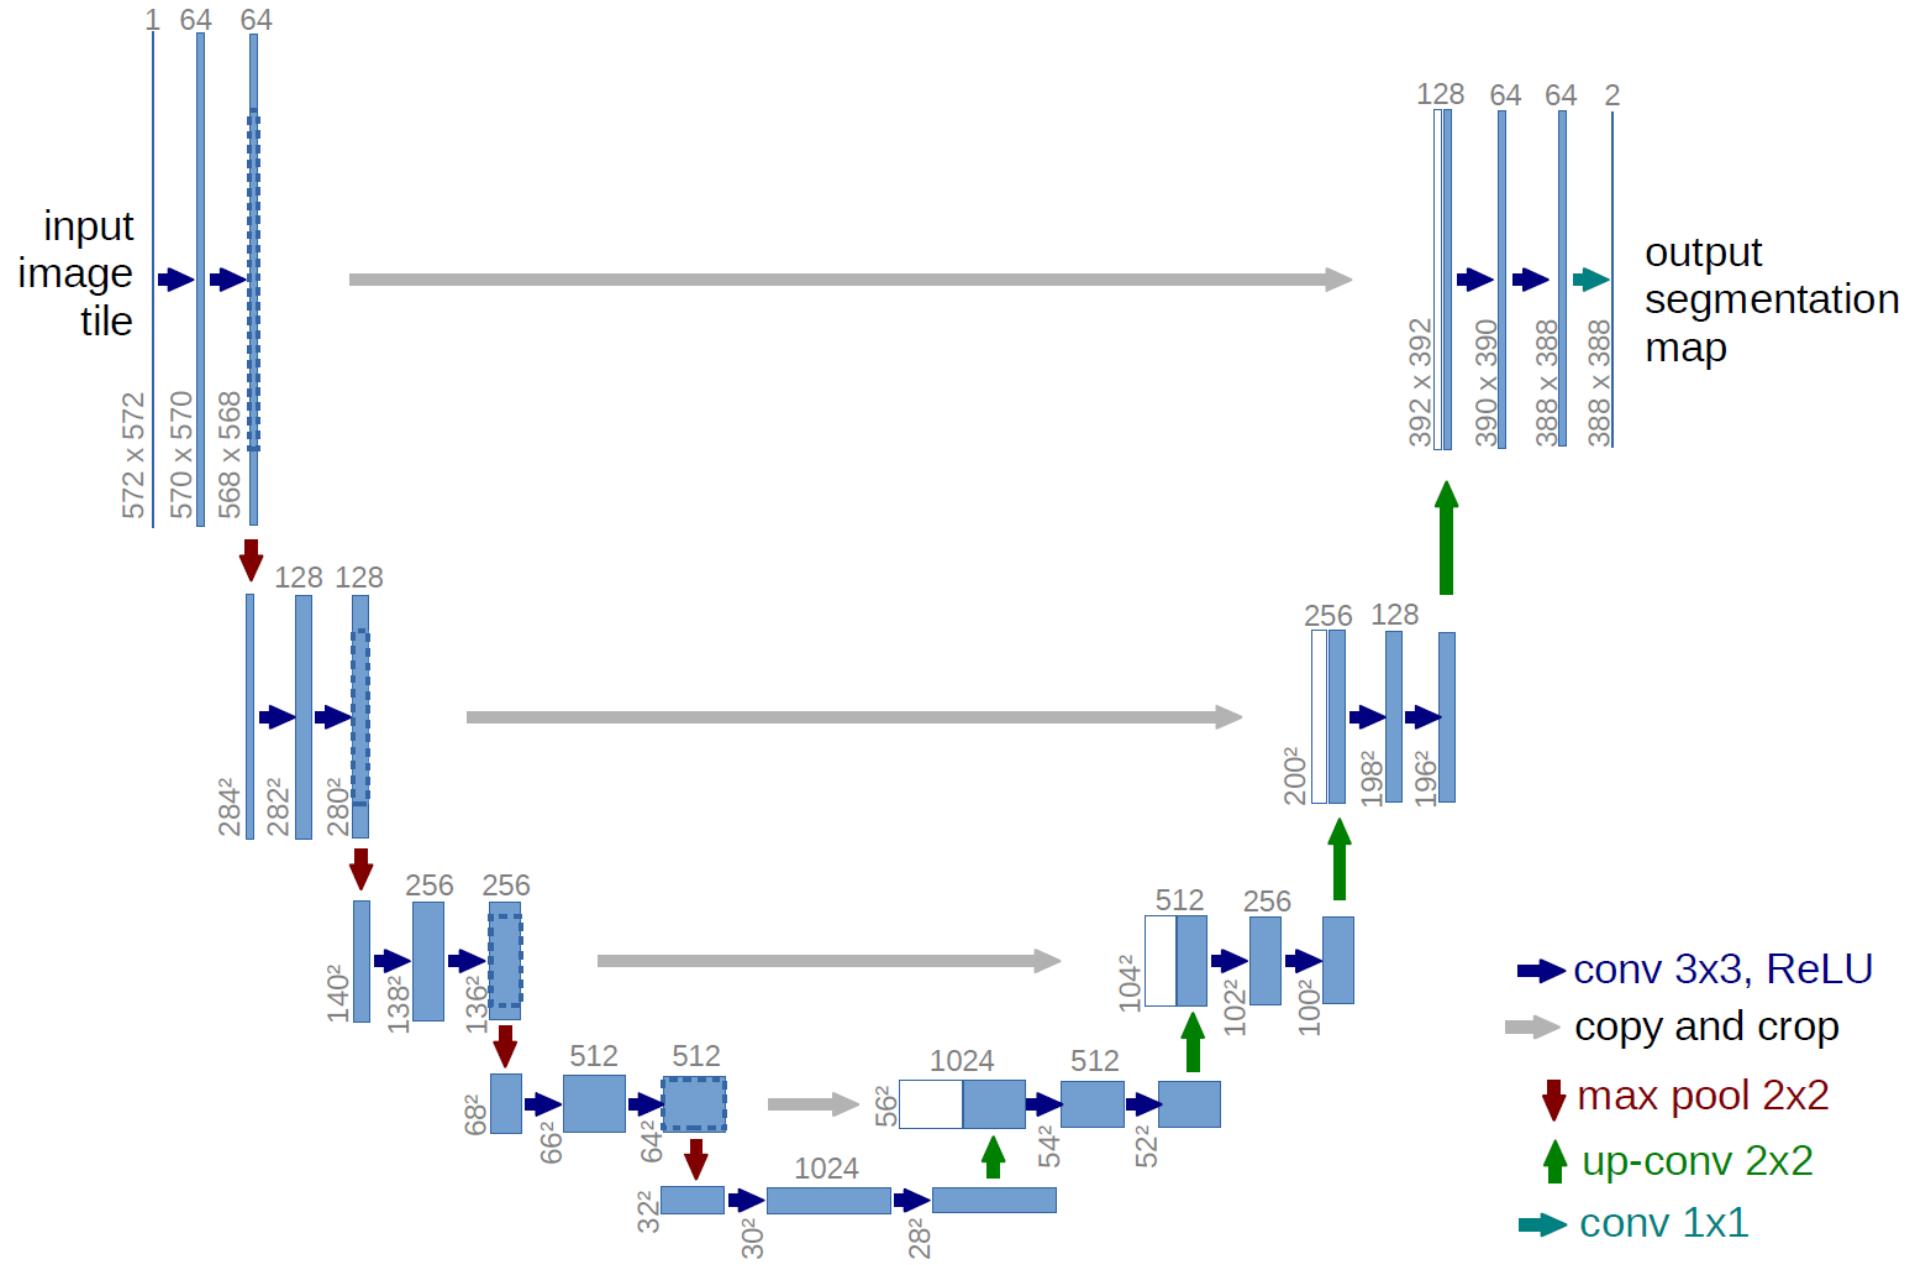
پروژه دانشگاهی: اگر پروژه برای یک کار دانشگاهی است که نیاز به اثبات یک مفهوم یا تست فرضیه‌های جدید دارد، می‌توانید از مدل‌های پیچیده‌تر مانند Attention U-Net استفاده کنید.

پروژه کاری/تجاری: اگر هدف پروژه تجاری یا کاربردی است که باید به نتایج دقیق و سریع دست یابید، انتخاب Net-U به عنوان یک روش امتحان شده و سریع، منطقی خواهد بود.

پروژه آموزشی: برای پروژه‌های آموزشی که هدف اصلی یادگیری و آموزش تکنیک‌های پایه‌ای است، U-Net یک انتخاب مناسب است به دلیل سادگی و مستندات گسترده.

توصیه: حتماً بلوک دیاگرام روش انتخابی را با جزئیات رسم کنید

U-Net:



◦ پیاده سازی گام به گام روش انتخابی در #گام_5

پس از انتخاب روش مناسب، پیاده سازی باید به صورت گام به گام انجام شود تا اطمینان حاصل شود که تمامی مراحل به درستی اجرا می شوند. پیاده سازی موفقیت آمیز شامل طراحی ساختار کلی پروژه، توسعه هر بخش از مدل، و اجرای فرآیندهای آموزشی و ارزیابی است.

◦ نحوه پیاده سازی یک روش در یادگیری عمیق

▪ طراحی بلوك دیاگرام پروژه (Workflow Project)

ورودی تصویر: دریافت و پیش پردازش تصاویر. MRI.

مدل تقسیم‌بندی: پیاده سازی مدل انتخابی مانند U-Net.

خروجی: تولید نقشه های تقسیم‌بندی بطن چپ (LV).

ارزیابی: مقایسه خروجی مدل با داده های واقعی برای ارزیابی دقیق.

▪ پیاده سازی تک تک بلوكها

▪ دیباگ و تست هر بلوك جهت اطمینان از صحت پیاده سازی

▪ مراحل

▪ داده

▪ تهییه داده

▪ دیتاست مناسب و استاندارد موجود هست.

▪ دیتاست مرتبط هست. اما استاندارد نیست. نیاز به اصلاح دارد.

▪ استفاده از دیتاست های موجود برای ساختن دیتاست مناسب بالاهدافمان.

▪ خودمان باید دیتاست جمع آوری کنیم. به سختی قابل فرموله کردن هست.

▪ دیتاست مناسب و استاندارد موجود است: دیتاست ACDC به طور کامل آماده و بر چسب گذاری شده است.

▪ تحلیل اکتشافی داده (EDA)

▪ مشاهده و بررسی نمونه ها

⚠ تمامی حقوق این محتوا متعلق به آکادمی هوبات است. هرگونه کپی برداری و انتشار غیر مجاز ممنوع می باشد

▪ رسم نمودارهای تحلیلی مختلف باهدف برقراری ارتباط بداده

مشاهده و بررسی نمونه‌ها: مشاهده چند نمونه از تصاویر و برچسب‌های موجود برای درک بهتر داده‌ها.

رسم نمودارهای تحلیلی: تحلیل توزیع داده‌ها و شناسایی ناهنجاری‌ها.

▪ دیتاست چه می‌گوید؟

تحلیل داده‌ها یکی از مراحل حیاتی در هر پروژه یادگیری عمیق است. این مرحله شامل بررسی دقیق دیتاست و استخراج اطلاعات کلیدی است که به درک بهتر از داده‌ها و بهینه‌سازی مدل کمک می‌کند. در این بخش، به بررسی چند جنبه کلیدی از داده‌ها می‌پردازم:

1. توزیع داده‌ها

توزیع کلاس‌ها: آیا داده‌ها به صورت متوازن بین کلاس‌ها توزیع شده‌اند؟ به عنوان مثال، در پروژه LV Segmentation تعداد نمونه‌های مربوط به هر یک از بخش‌های قلب (بطن چپ، بطن راست، میوکارد) تقریباً برابر است؟

توزیع جغرافیایی/زمانی: اگر داده‌ها از منابع مختلف یا در زمان‌های مختلف جمع‌آوری شده‌اند، توزیع آن‌ها چگونه است؟ آیا تفاوت‌های قابل توجهی بین داده‌های مختلف وجود دارد؟

2. کیفیت داده‌ها

وضوح و کیفیت تصاویر: آیا تصاویر دارای وضوح کافی برای تشخیص ویژگی‌های کلیدی هستند؟ آیا نویز یا مشکلات دیگر در داده‌ها وجود دارد که ممکن است بر عملکرد مدل تأثیر بگذارد؟

برچسب‌گذاری: بررسی کنید که برچسب‌های داده‌ها (Labels) چقدر دقیق و قابل اعتماد هستند. آیا نیاز به اصلاح یا بهبود برچسب‌ها وجود دارد؟

3. قابلیت تعمیم‌پذیری داده‌ها

تنوع داده‌ها: آیا داده‌های موجود نماینده خوبی از تنوع موجود در دنیای واقعی هستند؟ مثلاً آیا داده‌ها شامل نمونه‌هایی از بیماران مختلف با شرایط قلبی متنوع هستند؟

تأثیر تنوع داده‌ها بر تعمیم‌پذیری مدل: مدل چگونه با داده‌های جدید و دیدنشده برخورد می‌کند؟ آیا تنوع کافی در دیتاست وجود دارد تا مدل بتواند با داده‌های واقعی و متنوع عملکرد خوبی داشته باشد؟

▪ آماده سازی و پیش پردازش داده

- رفع ایرادهای ابتدایی در دیتاست (مثل، حذف/اصلاح داده‌های بدون برچسب، خراب و غیره)
- تقسیم داده به بخش‌های validation و train
- داده‌افزایی (Augmentation Data)
- نرمال سازی و استاندارد سازی داده
- پیاده سازی مازول فراخوانی داده
- دیتاست در پایتون چ آماده هست
- دستور مناسب برای فراخوانی در پایتون چ وجود دارد ImageFolder
- کاستوم دیتاست در اینترنت موجود هست
- می‌تواند بنویسید ChatGPT
- خودمان باید کاستوم دیتاست را بنویسیم

▪ مدل

- مدل و روش مدنظر ما آماده موجود هست
- مدل/روش در اینترنت به شکل ساده و تمیز موجود هست
- مدل/روش قابل پیاده‌سازی توسط GPT هست
- خودمان باید مدل/روش را پیاده سازی کنیم
- چرخ را از نو اختراع نکنید
- ترجیحاً از مدل‌های پایه آماده استفاده کنید
- مدل‌های آماده و معروف آزمون خود را پس داده‌اند
- یک پروژه جدی، جای پیاده سازی رزنت از صفر نیست



⚠ تمامی حقوق این محتوا متعلق به آکادمی هوبات است. هرگونه کپی‌برداری و انتشار غیرمجاز ممنوع می‌باشد.

▪ پیکربندی

▪ تعریف مدل با آرگومان‌های مناسب

تعیین تعداد لایه‌ها، فیلترها و سایر پارامترهای مدل.

▪ تعریفتابع اقلاف مناسب، تابع اقلاف با توجه به نسک تعریف می‌شود

▪ تعریف بهینه ساز

▪ SGD و ADAM روش‌های معمول قدیمی

▪ معرفی میزان پارامترهای مدل به بهینه ساز

▪ تعیین‌های پارامترهای مهم مانند نرخ یادگیری و غیره

▪ تنظیم های پارامترها

▪ تعریف معیار ارزیابی

استفاده از معیارهای مانند Dice coefficient یا IoU برای ارزیابی کیفیت تقسیم‌بندی.

▪ توابع آموزش و ارزیابی

▪ Train تابع کدنویسی

▪ Test/Evaluate/Validation

▪ استفاده از ابزارها/کدها/تکنیک‌های جانبی برای حرفه‌ای شدن

▪ مانیتورینگ منحنی یادگیری مدل حین آموزش (Curve Learning) TensorBoard <---

Analyze Curve Learning —> WandB, Tensorboard, Matplotlib

▪ چاپ منظم و بایرنامه اطلاعات آموزش مدل

▪ ذخیره بهترین مدل

▪ توقف آموزش مدل در شرایط اورفیت

▪ آموزش مدل

▪ دغدغه‌های مادرآموزش بهینه مدل

▪ داده

▪ مدل

▪ بهینه ساز

▪ نرخ یادگیری

▪ مومنتوم

▪ Weight Decay

▪ میزان پارامترهای یادگیری

▪ تعداد ایپاک و غیره

▪ دستور پخت آموزش بهینه مدل

1. مشاهده مقدار اتلاف مدل آموزش روی چند نمونه بج دیده نشده

هدف: بررسی اولیه عملکرد مدل در مراحل ابتدایی آموزش.

روش: چند نمونه از داده‌ها را از مجموعه تست یا validation انتخاب کنید.

این داده‌ها را از مسیر فوروارد مدل عبور دهید.

مقدار اتلاف (Loss) را برای این داده‌ها محاسبه کنید و مقدار حدودی را یادداشت کنید.

نتیجه: این کار به شما اطمینان می‌دهد که مسیر فوروارد مدل به درستی کار می‌کند و همچنین یک مرجع اولیه برای مقایسه اتلاف‌های بعدی در اختیار دارید.

2. مدل را روی تعداد بسیار کمی داده آموزش دهید

هدف: اطمینان از اینکه مدل قادر به یادگیری و اورفیت شدن روی داده‌های کم است.

روش: یک زیرمجموعه کوچک از داده‌های آموزشی را انتخاب کنید.

مدل را روی این داده‌ها آموزش دهید تا جایی که مدل کاملاً اورفیت شود (یعنی دقت بسیار بالایی روی داده‌های آموزشی و اتلاف نزدیک به صفر داشته باشد).

نتیجه ---> موفقیت در اورفیت: مدل به درستی آموزش دیده و مسیر فوروارد و بکوارد آن به درستی کار می‌کند.

عدم اورفیت: ممکن است مشکل در فرآیند آموزش (مانند مسیر فوروارد یا بکوارد) یا ضعف مدل در یادگیری داده‌ها وجود داشته باشد.

3. مدل را با نرخ‌های یادگیری مختلف برای تعداد کمی ایپاک آموزش دهید

▪ هدف، یافتن بهترین نرخ یادگیری است

▪ نرخ‌های یادگیری پیشنهادی: 0.0001، 0.001، 0.01، 0.1، 0.09 وغیره

▪ مومتنوم را روی 0.9 قرار دهید

▪ نرخ یادگیری ای خوب هست که بیشترین کاهش اتلاف را ایجاد کند

4. یک Grid Search **حوالی بهترین نرخ یادگیری** ایجاد کنید

▪ هدف، یافتن مقدار دقیق‌تر برای نرخ یادگیری

5. برای تعداد ایپاک طولانی (10 تا 15) مدل را آموزش دهید

▪ این مرحله آموزش واقعی است

▪ اگر کاهش مدل ادامه داشت، دوباره گام 5 را تکرار کنید

▪ اگر کاهش اتلاف مشاهده نشد، به گام 3 بازگردید. نیاز به تغییر نرخ یادگیری دارید. البته، ادامه کار باید براساس بهترین مدل

این مرحله ادامه یابد

هدف: انجام آموزش نهایی مدل با استفاده از تنظیمات بهینه‌یافته.

روش:

مدل را برای تعداد ایپاک طولانی آموزش دهید (معمولًاً بین 10 تا 15 ایپاک).

نتیجه:

کاهش ادامه‌دار اتلاف: آموزش را ادامه دهید تا زمانی که اتلاف بهطور مداوم کاهش یابد.

توقف کاهش اتلاف: اگر کاهش اتلاف متوقف شد، نیاز به تنظیم دوباره نرخ یادگیری یا سایر تنظیمات است. به گام 3 بازگردید و تغییرات لازم را اعمال کنید.

▪ ارزیابی

هدف : ارزیابی عملکرد نهایی مدل و اطمینان از کارایی آن.

▪ ارزیابی بهترین مدل

▪ همان تابع ارزیابی که قبلاً پیاده‌سازی شد (Evaluate)

▪ پیش‌بینی مدل به‌ازای یک چند نمونه داده

▪ کارکردی مشابه با بهره‌برداری عملی از یک پروژه انجام شده

▪ آماده‌سازی مدل برای استفاده در شرایط عملی و پیش‌بینی داده‌های جدید.

▪ این کارد قالب تابعی با عنوان — انجام می‌شود (inference)

به فرآیند استفاده از یک مدل آموزش‌دهنده برای پیش‌بینی یا استنتاج نتایج بر اساس داده‌های جدید و دیده‌نشده گفته می‌شود. در زمینه تقسیم‌بندی تصاویر پزشکی، مانند پروژه LV Segmentation، فرآیند inference شامل استفاده از مدل برای تقسیم‌بندی تصاویر MRI جدید است

◦ آزمایش و تحلیل مدل آموزش دیده

- هدف : آزمایش مدل آموزش دیده برای ارزیابی عملکرد آن بر روی داده های جدید و بررسی صحت عملکرد مدل.
- روش : اجرای مجموعه های از تست ها و تحلیل ها برای بررسی کیفیت و کارایی مدل. این آزمایش ها شامل ارزیابی دقت مدل، شناسایی نقاط قوت و ضعف، و بررسی عملکرد مدل در شرایط مختلف است.

◦ اهداف پروژه، با آزمایش می خواهیم

▪ اثبات کنیم که ادعای ما درست هست. چه ادعایی؟

- ادعا : مدل پیشنهادی قادر است با دقت بالا بطن چپ قلب را در تصاویر MRI تقسیم بندی کند.
- روش : اجرای آزمایش های دقیق برای اثبات اینکه مدل در شرایط مختلف و بر روی دیتاست های مختلف با دقت بالایی عمل می کند.

▪ میزان کارایی روش ارائه شده را سنجیم

- هدف : ارزیابی دقت، سرعت و کارایی مدل در انجام تسک های تعریف شده.
- روش : استفاده از معیار های ارزیابی مانند Dice coefficient ، IoU، و سرعت پردازش برای سنجش عملکرد مدل.

▪ نقاط قوت و ضعف روش پیاده سازی شده را شناسایی کنیم ---> گاهی از همین آزمایش هاست که راه حل های جدید پیدا می شود

▪ ارزیابی مأذول های مختلف پروژه انجام شده

▪ مدل های مختلف

- هدف : مقایسه مدل های مختلف مانند U-Net ، Attention U-Net و V-Net برای تعیین بهترین مدل در پروژه.
- روش : اجرای آزمایش ها بر روی هر مدل و مقایسه نتایج بر اساس معیار های دقت و کارایی.

▪ هایپر پارامترهای پیشنهادی

- هدف : بررسی تاثیر تغییرات هایپر پارامترها بر عملکرد مدل.
- روش : تغییر هایپر پارامترهای مانند نرخ یادگیری، مومنتوم، و تعداد لایه ها و مشاهده تغییرات در نتایج.

▪ چند نمونه از آزمایش های رایج در پروژه های یادگیری عمیق

▪ ارزیابی مدل روی دیتاست های مختلف

▪ آموزش روی یک دیتاست و ارزیابی روی دیتاست دیگر

- بررسی اثر مدل‌ها، مازول‌ها، هایپرپارامترهای مختلف
- یافتن دلیل بروز خطاها و عملکرد خوب ---> روی کدام جنس نفوذ هابیشترین خطارداریم؟
- درک عملکرد مدل ---> مصورسازی خروجی نهایی/میانی مدل

هدف: فهم بهتر عملکرد مدل از طریق مصورسازی خروجی‌های میانی و نهایی.

روش:

نمایش نقشه‌های احتمال: مشاهده و تحلیل نقشه‌های احتمال تولید شده توسط مدل.

نمایش نقشه‌های تقسیم‌بندی: مصورسازی نقشه‌های نهایی که مدل تولید کرده است و مقایسه آن‌ها با داده‌های واقعی.

استفاده از ابزارهای مصورسازی: استفاده از ابزارهایی مانند Matplotlib یا TensorBoard برای ایجاد نمودارهای تحلیلی و مصور کردن عملکرد مدل در طول آموزش و ارزیابی.

○ چه کارهایی در راستای بهترشدن پروژه می‌توان انجام داد؟

تنظیم دقیق‌تر هایپرپارامترها: بهینه‌سازی هایپرپارامترهایی مانند نرخ یادگیری، مومنتوم، و اندازه بج می‌تواند منجر به بهبود دقت مدل شود. انجام Grid Search یا Random Search برای یافتن تنظیمات بهینه می‌تواند مفید باشد.

افزایش داده‌های آموزشی: استفاده از تکنیک‌های داده‌افزایی (Data Augmentation) بیشتر یا جمع‌آوری داده‌های جدید می‌تواند به بهبود عملکرد مدل کمک کند، به خصوص در مواردی که داده‌ها محدود هستند.

استفاده از مدل‌های پیچیده‌تر یا ترکیبی: ممکن است استفاده از مدل‌های پیچیده‌تر مانند مدل‌های مبتنی بر Transformer یا ترکیب چند مدل به دقت بهتری منجر شود. کاهش پیچیدگی مدل: در صورتی که مدل شما به دلیل پیچیدگی زیاد چار اورفیت می‌شود، ساده‌سازی مدل (کم کردن تعداد لایه‌ها یا فیلترها) می‌تواند مفید باشد.

بهبود پیش‌پردازش داده‌ها: اعمال تکنیک‌های پیش‌پردازشی خاص‌تر یا بهبود کیفیت داده‌های ورودی می‌تواند تاثیر مثبتی بر عملکرد مدل داشته باشد.

آموزش مدل پا داده‌های بیشتر یا متفاوت: بررسی امکان استفاده از دیتاست‌های دیگر یا ترکیب دیتاست‌های مختلف برای افزایش تنوع و غنای داده‌ها.

استفاده از یادگیری انتقالی (Transfer Learning): استفاده از مدل‌های از پیش آموزش دیده برای تسریع فرآیند آموزش و بهبود دقت مدل.

○ این کارها را انجام دهید یا برای آینده‌گان یادداشت بگذارید

○ یکی از بهترین زمان‌های ممکن برای ارائه پیشنهادهای بهبود؛ (بعد از اتمام پروژه！)

بهترین زمان: بعد از اتمام پروژه و انجام تمامی آزمایش‌ها و ارزیابی‌ها، زمانی است که شما به درک کاملی از عملکرد مدل و نقاط قوت و ضعف آن رسیده‌اید. این بهترین زمان برای پیشنهاد بهبودها است.

چرخه بهبود: پس از اتمام پروژه، پیشنهادهای بهبود می‌تواند به عنوان یک چرخه تکراری برای بهبود مستمر مدل و فرآیندهای مرتبط با آن اعمال شود.

○ جستجو، مطالعه، پیاده‌سازی و آزمایش‌ها شما را به بلوغ رسانده است

تجربه کسب شده: فرآیند جستجو، مطالعه و پیاده‌سازی که در طول پروژه انجام داده‌اید، شما را درک عمیق‌تری از مفاهیم یادگیری عمیق و فرآیندهای مرتبط با آن رسانده است.

استفاده از این تجربه: از تجربه‌ها و دانش کسب شده در پروژه‌های آینده استفاده کنید و بهبودهای پیشنهادی را در سایر پروژه‌ها نیز اعمال کنید.

اشتراک‌گذاری دانش: دانش و تجربه‌های بهدست‌آمده را با تیم خود یا جامعه بزرگ‌تر به اشتراک بگذارید تا دیگران نیز از این بلوغ بهره‌مند شوند.

◦ تبدیل پروژه به یک محصول فانزی

هدف: پروژه خود را به یک محصول کاربردی تبدیل کنید که استفاده از آن لذت‌بخش باشد و تجربه‌ای عملی از نتیجه کار شما ارائه دهد. این محصول قرار نیست تجاری باشد؛ هدف اصلی این است که بتوانید نتایج کار خود را در یک قالب کاربردی مشاهده و تجربه کنید.

▪ فعلاً سخت‌نگیر و به محصول تجاری نکردن (پروژه آموزشی)

▪ یک محصولی بساز که صرفاً خودت از دیدنش لذت ببری (پروژه آموزشی)

مثال‌ها:

ایجاد یک نرم‌افزار دسکتاپ یا وب‌اپلیکیشن که تصاویر MRI را پردازش کرده و نتایج تقسیم‌بندی را به صورت بصری نمایش دهد.

ساخت یک برنامه ساده که بتواند تصاویر جدید را از یک پوشه مشخص پردازش کرده و نتایج تقسیم‌بندی را ذخیره کند.

◦ از دیوايس‌های ورودی در کامپیوتر استفاده کنید

▪ وب‌کم

▪ میکروفون

▪ کیبورد

◦ مستند کردن هر آنچه که در پروژه انجام شده است

هدف : مستندسازی به طور دقیق و جامع از تمامی مراحل پروژه به طوری که دیگران بتوانند پروژه را باز تولید کنند و به فهم کاملی از فرآیند و نتایج دست یابند.
مستندسازی باید شامل توضیحات، نتایج، و تمام تصمیمات فنی باشد که در طول پروژه گرفته شده است.

◦ مواردی که باید مستند و نهایی شود

▪ گزارشی شامل شرح انجام پروژه

▪ بیان مساله

▪ بررسی کارهای گذشته

▪ روش پیاده سازی شده

▪ دلیل انتخاب این روش

▪ نیازی به آوردن کدها نیست

▪ آزمایش‌ها

▪ پیشنهادها

▪ نکات فنی

▪ جزئیاتی مانند ورزن فریمورک‌ها، سیستم عامل و... را ثبت کنید

▪ مانند گیت‌هاب، تغییرات/اصلاحات/بهبودها در گزارش را ثبت کنید

▪ داده‌ها

▪ حتماً برای داده‌های فکر اساسی کنید

▪ می‌توانیم آدرس دیتاباست‌ها در گزارش بنویسیم، اما اگر بعداً آدرس دانلود داده‌ها بعده کار نکرد، چه؟

▪ ذخیره داده‌ها، با رگزاری در سوررهای اختصاصی



مدل‌ها

- بهترین مدل‌های خود را با اسم مناسب ذخیره کنید
- در گزارش، در قالب یک جدول درمورد مدل‌ها توضیح دهید

کدها

- کدها را با ساختار، پوشش‌بندی و اسم مناسب تنظیم کنید
- برای کدها به اندازه استاندارد کامنت بنویسید
- کدها را براساس استایل/استانداردهای رایج مانند پپ8 آماده کنید

<https://peps.python.org/pep-0008/>

- در گزارش، نحوه اجرای کدها و نصب پیش‌نیازها را بنویسید

ReadMe

- خالصه‌ای از گزارش
- توضیح کوتاه پرتو، توضیح کوتاه از روش (به همراه شکل) و نتایج
- پیش‌نیازهای اجرا، نحوه اجرای کدها، گزارش تغییرات و توسعه‌دهنده‌ها

Powerpoint

نکته: مستندسازی به صورت مدام:

- به جای مستندسازی فقط در انتهای، مستندسازی در طول پروژه به صورت مرحله به مرحله انجام شود. این رویکرد باعث می‌شود که اطلاعات به روز و دقیق باشد و از فراموشی جزئیات جلوگیری شود.

▪ ارزیابی اولیه مدل:(Initial Model Evaluation)

- پس از پیاده‌سازی اولیه مدل، قبل از رفتن به مرحله "آزمایش"، یک مرحله "ارزیابی اولیه مدل" داشته باشید که در آن، عملکرد مدل به سرعت بر اساس یک مجموعه داده کوچک ارزیابی شود. این گام به شما کمک می‌کند تا مشکلات بزرگ را در مراحل اولیه شناسایی و حل کنید و وقت و منابع را صرف بهینه‌سازی بی‌فایده نکنید.

⚠ تمامی حقوق این محتوا متعلق به آکادمی هوبات است. هرگونه کپی‌برداری و انتشار غیرمجاز ممنوع می‌باشد